

GLiNER

Generalist Model for Named Entity Recognition using Bidirectional Transformer

CS221.Q12 - Xử lý ngôn ngữ tự nhiên

Nhóm 10

Nguyễn Thanh Tùng – 23521745

Mai Lê Bá Vương – 23521821

Chường Hồng Văn – 23521769

TP. Hồ Chí Minh, 2025

Mục lục

- 1 Giới thiệu
- 2 Động lực
- 3 Hướng tiếp cận
- 4 Thực nghiệm & Kết quả
- 5 Tổng kết

Mục lục

- 1 Giới thiệu
- 2 Động lực
- 3 Hướng tiếp cận
- 4 Thực nghiệm & Kết quả
- 5 Tổng kết

GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer

Tác giả: Urchade Zaratiana, Nadi Tomeh, Pierre Holat, Thierry Charnois

Công bố tại: NAACL 2024

- Bài toán: Named Entity Recognition (NER)
- Mục tiêu: nhận dạng **bất kỳ loại thực thể nào** theo yêu cầu người dùng

Mục lục

- 1 Giới thiệu
- 2 Động lực**
- 3 Hướng tiếp cận
- 4 Thực nghiệm & Kết quả
- 5 Tổng kết

Bối cảnh và hạn chế của NER

- **Named Entity Recognition (NER)** là thành phần quan trọng trong nhiều hệ thống NLP
- **Các mô hình NER truyền thống tồn tại nhiều hạn chế:**
 - Chỉ hỗ trợ tập entity type cố định
 - Phụ thuộc mạnh vào dữ liệu gán nhãn
- **Việc mở rộng entity type trong thực tế:**
 - Cần gán nhãn lại dữ liệu
 - Cần huấn luyện lại mô hình
- **Hệ quả:** chi phí cao và kém linh hoạt khi triển khai

Các hướng tiếp cận dựa trên LLM

• LLM Prompting

- Trích xuất thực thể thông qua prompt ngôn ngữ tự nhiên
- Hạn chế:
 - Mô hình rất lớn
 - Khó triển khai trong môi trường tài nguyên hạn chế

• LLM thông qua API

- Hạn chế:
 - Chi phí cao khi sử dụng ở quy mô lớn
 - Phụ thuộc vào dịch vụ bên thứ ba

• Fine-tuning LM open-source cho NER

- InstructUIE, GoLLIE, UniversalNER
- Trong thiết lập zero-shot, các phương pháp này **không chỉ tái tạo mà còn vượt qua hiệu năng của ChatGPT**

- **Hạn chế chung của các phương pháp hiện tại:**
 - Phụ thuộc vào mô hình sinh tự hồi quy
 - Suy luận chậm
 - Kích thước mô hình lớn, tiêu tốn tài nguyên


Mục lục

- 1 Giới thiệu
- 2 Động lực
- 3 Hướng tiếp cận**
- 4 Thực nghiệm & Kết quả
- 5 Tổng kết

Ý tưởng và tổng quan mô hình GLiNER

- Không sử dụng các mô hình sinh tự hồi quy (autoregressive) quy mô lớn mà mô hình dựa trên **Bidirectional Language Models (BiLM)**.
- Ý tưởng cốt lõi: xem OpenNER như một bài toán **so khớp trong không gian tiềm ẩn**
 - So khớp embedding của **entity type**
 - Với embedding của **span văn bản**
- Kiến trúc mô hình gồm ba thành phần chính:
 - Bộ mã hóa văn bản đã huấn luyện sẵn
 - Mô-đun biểu diễn span
 - Mô-đun biểu diễn loại thực thể

Kiến trúc mô hình



Hình 1: Kiến trúc mô hình

Định dạng đầu vào của mô hình

- Đầu vào của GLiNER là một chuỗi hợp nhất gồm:
 - Danh sách các loại thực thể **được biểu diễn bằng ngôn ngữ tự nhiên**
 - Văn bản đầu vào cần trích xuất thực thể
- Mỗi loại thực thể được đặt trước bởi một token đặc biệt [ENT]
- Token [SEP] được dùng để phân tách phần entity types và văn bản
- Toàn bộ chuỗi được đưa vào BiLM để học tương tác ngữ cảnh

Ví dụ:

[ENT] person [ENT] organization [SEP] Barack Obama was born in Hawaii and served as president of the United States.

[ENT] t_0 [ENT] t_1 ... [ENT] t_{M-1} [SEP] x_0 x_2 ... x_{N-1}

Hình 2: Ví dụ về định dạng input của GLiNER

Biểu diễn token

- Chuỗi đầu vào được mã hóa bởi Bidirectional Language Model (BiLM) để tạo ra các biểu diễn ngữ cảnh hóa cho mọi token
- Biểu diễn của các token [ENT] được ký hiệu là $\mathbf{p} = \{p_i\}_{i=0}^{M-1} \in \mathbb{R}^{M \times D}$, đại diện cho các loại thực thể
- Biểu diễn của các token trong văn bản được ký hiệu là $\mathbf{h} = \{h_i\}_{i=0}^{N-1} \in \mathbb{R}^{N \times D}$, dùng để xây dựng các span

Lưu ý: nếu một từ được tách thành nhiều subword, mô hình chỉ sử dụng biểu diễn của subword đầu tiên.

Biểu diễn Entity và Span

Mục tiêu: ánh xạ **entity types** và **span** vào cùng một không gian tiềm ẩn

Biểu diễn entity:

- Biểu diễn entity ban đầu $\mathbf{p}$ được tinh chỉnh bằng một mạng FFN hai tầng
- Thu được biểu diễn entity:

$$\mathbf{q} = \{q_i\}_{i=0}^{M-1} \in \mathbb{R}^{M \times D}$$

Biểu diễn span:

- Span bắt đầu tại vị trí i và kết thúc tại vị trí j được biểu diễn bởi:

$$S_{ij} = \text{FFN}(h_i \otimes h_j), \quad S_{ij} \in \mathbb{R}^D \quad (1)$$

- Trong đó, $\otimes$ là phép nối vector và FFN là mạng feedforward hai tầng
- Độ dài span được giới hạn bởi $K = 12$ để đảm bảo độ phức tạp tuyến tính

So khớp Entity Type và Span

- Mục tiêu: đánh giá mức độ phù hợp giữa một span (i, j) và một loại thực thể t

Hàm so khớp:

$$\phi(i, j, t) = \sigma(S_{ij}^\top q_t) \in \mathbb{R} \quad (2)$$

- S_{ij} : biểu diễn của span bắt đầu tại i và kết thúc tại j
- q_t : biểu diễn của entity type t
- $\sigma(\cdot)$: hàm sigmoid

Giá trị $\phi(i, j, t)$ có thể được diễn giải là *xác suất span (i, j) thuộc về loại thực thể t* , do mô hình được huấn luyện với binary cross-entropy loss.

- Mục tiêu huấn luyện:
 - Tăng điểm so khớp cho các cặp **span–entity đúng** (positive pairs)
 - Giảm điểm so khớp cho các cặp **sai** (negative pairs)
- Với mỗi cặp $s = (i, j, t)$:
 - $s \in \mathcal{P}$ nếu span (i, j) có nhãn entity type t
 - $s \in \mathcal{N}$ nếu ngược lại

Hàm mất mát (Binary Cross-Entropy):

$$\mathcal{L}_{\text{BCE}} = - \sum_{s \in \mathcal{S} \times \mathcal{T}} \left[\mathbb{I}_{s \in \mathcal{P}} \log \phi(s) + \mathbb{I}_{s \in \mathcal{N}} \log(1 - \phi(s)) \right] \quad (3)$$

Trong đó, $\mathbb{I}$ là hàm chỉ thị và $\phi(s)$ là điểm so khớp span–entity.

- Trong giai đoạn decoding, mô hình sử dụng **chiến lược greedy** để chọn span
- Việc suy luận được thực hiện **độc lập cho từng câu**
- Chỉ các span (i, j, t) có điểm so khớp $\phi(i, j, t) > 0.5$ mới được đưa vào quá trình lựa chọn

Mục lục

- 1 Giới thiệu
- 2 Động lực
- 3 Hướng tiếp cận
- 4 Thực nghiệm & Kết quả**
- 5 Tổng kết

- **Dữ liệu huấn luyện: Pile-NER**

- Lấy mẫu từ *Pile corpus*, gán nhãn tự động bằng **ChatGPT**
- Quy mô: $\sim 45\text{K}$ passages, $\sim 240\text{K}$ entity spans, $\sim 13\text{K}$ distinct entity types

- **Cấu hình mô hình (Configuration)**

- Backbone: DeBERTa-v3 (S/B/L)
- AdamW optimizer, lr $1e^{-5}$ (pretrained layers), $5e^{-5}$ (non-pretrained layers)
- Kỹ thuật đặc biệt: Negative Entity Sampling và Entity Type Dropping.

- **Baselines**

- Prompting LLMs: ChatGPT, Vicuna
- Fine-tuned LLMs: InstructUIE (11B), UniNER (7B/13B), GoLLIE (7B)
- Mô hình khác: USM

Các bộ dữ liệu đánh giá (Evaluation Datasets)

- **Phương pháp:** Zero-shot
- **Metric:** F1-score dựa trên exact match (span boundary và span type)
- **Dataset đánh giá:**
 - 1 **OOD NER Benchmark (Out-of-Domain)**
 - Gồm 7 bộ dữ liệu (CrossNER, MIT) thuộc các lĩnh vực chuyên biệt
 - 2 **20 NER Benchmark**
 - 20 bộ dữ liệu đa dạng (y sinh, tin tức, mạng xã hội, ...)
 - 3 **Đa ngôn ngữ (Multilingual)**
 - Sử dụng bộ dữ liệu **MultiCoNER**
 - Gồm 11 ngôn ngữ (Đức, Tây Ban Nha, Trung, Hàn, ...)

Kết quả trên OOD NER Benchmark

- **GLiNER-S** vượt các mô hình general-purpose (ChatGPT, Vicuna) và tốt hơn InstructUIE
- **GLiNER-M** đạt hiệu năng tương đương UniNER-13B dù kích thước nhỏ hơn ~ 140 lần
- **GLiNER-L** đạt **F1 = 60.9**, vượt các mô hình lớn hơn như ChatGPT và UniNER-13B

Model	Params	Movie	Restaurant	AI	Literature	Music	Politics	Science	Average
Vicuna-7B	7B	6.0	5.3	12.8	16.1	17.0	20.5	13.0	13.0
Vicuna-13B	13B	0.9	0.4	22.7	22.7	26.6	27.0	22.0	17.5
USM	0.3B	37.7	17.7	28.2	56.0	44.9	36.1	44.0	37.8
ChatGPT	–	5.3	32.8	52.4	39.8	66.6	68.5	67.0	47.5
InstructUIE	11B	63.0	21.0	49.0	47.2	53.2	48.1	49.2	47.2
UniNER-7B	7B	42.4	31.7	53.6	59.3	67.0	60.9	61.1	53.7
UniNER-13B	13B	48.7	36.2	54.2	60.9	64.5	61.4	63.5	55.6
GoLLIE	7B	63.0	43.4	59.1	62.7	67.8	57.2	55.5	58.0
GLiNER-S	50M	46.9	33.3	50.7	60.0	60.9	61.5	55.6	52.7
GLiNER-M	90M	42.9	37.3	51.8	59.7	69.4	68.6	58.1	55.4
GLiNER-L	0.3B	57.2	42.9	57.2	64.4	69.6	72.6	62.6	60.9

Hình 3: Zero-Shot Scores on Out-of-Domain NER Benchmark

Kết quả trên 20 NER Benchmark

- **GLiNER-L** đạt hiệu suất tốt nhất trên **13/20** bộ dữ liệu.
- Vượt **UniNER** trung bình 2 điểm F1 (F1-score = 47.8).
- Hiệu năng GLiNER thấp hơn UniNER trên dữ liệu mạng xã hội (tweet).

Dataset	ChatGPT	UniNER-7B	GLiNER-L
ACE05	26.6	36.9	27.3
AnatEM	30.7	25.1	33.3
bc2gm	40.2	46.2	47.9
bc4chemd	35.5	47.9	43.1
bc5cdr	52.4	68.0	66.4
Broad Tweeter	61.8	67.9	61.2
CoNLL03	52.5	72.2	64.6
FabNER	15.3	24.8	23.6
FindVehicle	10.5	22.2	41.9
GENIA	41.6	54.1	55.5
HarveyNER	11.6	18.2	22.7
MIT Movie	5.3	42.4	57.2
MIT Restaurant	32.8	31.7	42.9
MultiNERD	58.1	59.3	59.7
ncbi	42.1	60.4	61.9
OntoNotes	29.7	27.8	32.2
PolyglotNER	33.6	41.8	42.9
TweetNER7	40.1	42.7	41.4
WikiANN	52.0	55.4	58.9
WikiNeural	57.7	69.2	71.8
Average	36.5	45.7	47.8

Hình 4: Zero-shot scores on 20 NER datasets

Kết quả trên dữ liệu đa ngôn ngữ

- **Thiết lập:** Sử dụng biến thể GLiNER-Multi (backbone mdebert-v3)
- **Kết quả:**
 - **GLiNER-Multi** vượt **ChatGPT** trên **8/10 ngôn ngữ**
 - Tốt với ngôn ngữ **Latin** (Tây Ban Nha, Đức, ...)
 - Kém hơn trên ngôn ngữ **Non-Latin** (Bengali, Trung)

Language		Sup.	ChatGPT	GLiNER	
				En	Multi
Latin	German	64.6	37.1	35.6	39.5
	English	62.7	37.2	42.4	41.7
	Spanish	58.7	34.7	38.7	42.1
	Dutch	62.6	35.7	35.6	38.9
Non-Latin	Bengali	39.7	23.3	0.89	25.9
	Persian	52.3	25.9	14.9	30.2
	Hindi	47.8	27.3	11.3	27.8
	Korean	55.8	30.0	20.5	28.7
	Russian	59.7	27.4	30.3	33.3
	Turkish	46.8	31.9	22.0	30.0
	Chinese	53.1	18.8	6.59	24.3
Average		54.9	29.9	23.6	32.9

Hình 5: Zero-Shot Scores on Different Languages

In-domain Supervised Tuning

- GLiNER-L **pretrained** vượt trội so với phiên bản **non-pretrained**
- GLiNER-L tốt hơn **InstructUIE**, nhưng vẫn thấp hơn **UniNER-7B**


Dataset	InstructUIE	UniNER-7B	GLiNER-L	
	w/o	w/	w/	w/o
ACE05	79.9	86.7	82.8	81.3
AnatEM	88.5	88.5	88.9	88.4
bc2gm	80.7	82.4	83.7	82.0
bc4chemd	87.6	89.2	87.9	86.7
bc5cdr	89.0	89.3	88.7	88.7
Broad Twitter	80.3	81.2	82.5	82.7
CoNLL03	91.5	93.3	92.6	92.5
FabNER	78.4	81.9	77.8	74.8
FindVehicle	87.6	98.3	95.7	95.2
GENIA	75.7	77.5	78.9	77.4
HarveyNER	74.7	74.2	68.6	67.4
MIT Movie	89.6	90.2	87.9	87.5
MIT Restaurant	82.6	82.3	83.6	83.3
MultiNERD	90.3	93.7	93.8	93.3
ncbi	86.2	87.0	87.8	87.1
OntoNotes	88.6	89.9	89.0	88.1
PolyglotNER	53.3	65.7	61.5	60.6
TweetNER7	65.9	65.8	51.4	50.3
WikiANN	64.5	84.9	83.7	82.8
wikiNeural	88.3	93.3	91.3	91.4
Average	81.2	84.8	82.9	82.1

Hình 6: In-domain Supervised fine-tuning

Further Ablations

Negative Samples	Prec	Rec	F1
0%	49.3	58.1	53.3
50%	62.3	59.7	60.9
75%	61.1	56.5	58.6

Hình 7: Effect of negative entity types sampling



Hình 8: Randomly dropping entity types

Mục lục

- 1 Giới thiệu
- 2 Động lực
- 3 Hướng tiếp cận
- 4 Thực nghiệm & Kết quả
- 5 Tổng kết**

- **Hiệu năng vượt trội:** GLiNER vượt trội hơn các LLM (ChatGPT) trong tác vụ **Zero-shot NER**, dù có kích thước nhỏ hơn rất nhiều.
- **Hiệu quả tài nguyên:** GLiNER là giải pháp thay thế hiệu quả về tài nguyên cho các LLM lớn.
- **Khả năng tổng quát:** Mô hình hoạt động tốt trên nhiều ngôn ngữ, gồm cả những ngôn ngữ chưa từng xuất hiện trong tập huấn luyện.

- **Hạn chế**

- Chưa trích xuất được các thực thể bị ngắt quãng (*discontinuous entities*)
- Hiệu năng còn hạn chế trên các **ngôn ngữ phi Latin**.
- Việc đánh giá dựa trên **Exact Match** chưa phản ánh đầy đủ các trường hợp khớp một phần hoặc phụ thuộc ngữ cảnh.

- **Hướng phát triển**

- Cải thiện thiết kế mô hình để nâng cao hiệu suất tổng thể và hỗ trợ tốt hơn với **low-resource languages**.

- [1] Zhou et al. (2023).
UniversalNER: Targeted Distillation for Multi-Task NER.
Cung cấp bộ dữ liệu Pile-NER (dữ liệu huấn luyện chính) và mô hình UniNER.
- [2] He et al. (2021).
DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training.
Kiến trúc backbone giúp GLiNER tối ưu hóa khả năng mã hóa văn bản.
- [3] Wang et al. (2023).
InstructUIE: Multi-task Instruction Tuning for Unified IE.
Baseline đại diện cho hướng tiếp cận Instruction Tuning.
- [4] Sainz et al. (2023).
GoLLIE: Annotation Guidelines and One-Shot Learning for IE.
Cung cấp kỹ thuật Entity Dropping giúp tăng khả năng thích nghi.
- [5] Gao et al. (2020).
The Pile: An 800GB Dataset of Diverse Text for Language Modeling.
Nguồn dữ liệu thô quy mô lớn, nền tảng để tạo ra Pile-NER.
- [6] Malmasi et al. (2022).
MultiCoNER: A Large-scale Multilingual Dataset for NER.
Benchmark chuẩn dùng để đánh giá NER đa ngôn ngữ.

Cảm ơn cô và các bạn đã lắng nghe!